

11-2. 데이터 불러오기

데이터 살펴보기

- 테이블에 있는 10개의 행만 출력하기

```
SELECT *  
FROM `peppy-web-470203-s5.modulabs_project.project`  
LIMIT 10;
```

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate
1	536365	85123A	WHITE HANGING HEART T-LIG...	6	2010-12-4
2	536365	71053	WHITE METAL LANTERN	6	2010-12-4
3	536365	84406B	CREAM CUPID HEARTS COAT H...	8	2010-12-4
4	536365	84029G	KNITTED UNION FLAG HOT WA...	6	2010-12-4
5	536365	84029E	RED WOOLLY HOTTIE WHITE H...	6	2010-12-4
6	536365	22752	SET 7 BABUSHKA NESTING BO...	2	2010-12-4
7	536365	21730	GLASS STAR FROSTED T-LIGHT...	6	2010-12-4
8	536366	22633	HAND WARMER UNION JACK	6	2010-12-4
9	536366	22632	HAND WARMER RED POLKA DOT	6	2010-12-4
10	536367	84879	ASSORTED COLOUR BIRD ORN...	32	2010-12-4

[결과 이미지를 넣어주세요]

- 전체 데이터는 몇 행으로 구성되어 있는지 확인하기

```
SELECT COUNT(*) AS row_count  
FROM `peppy-web-470203-s5.modulabs_project.project`
```

[결과 이미지를 넣어주세요]

행	row_count
1	541909

데이터 수 세기

- COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기

```
SELECT  
COUNT(InvoiceNo) AS cnt_InvoiceNo,  
COUNT(StockCode) AS cnt_StockCode,  
COUNT(Description) AS cnt_Description,  
COUNT(Quantity) AS cnt_Quantity,  
COUNT(InvoiceDate) AS cnt_InvoiceDate,  
COUNT(UnitPrice) AS cnt_UnitPrice,  
COUNT(CustomerID) AS cnt_CustomerID,  
COUNT(Country) AS cnt_Country  
FROM `peppy-web-470203-s5.modulabs_project.project`;
```

[결과 이미지를 넣어주세요]

행	cnt_InvoiceNo	cnt_StockCode	cnt_Description	cnt_Quantity	cnt_InvoiceDate	cnt_UnitPrice	cnt_CustomerID	cnt_Country
1	541909	541909	540455	541909	541909	541909	406829	541909

11-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- 각 컬럼 별 누락된 값의 비율을 계산
 - 각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기

```

SELECT 'InvoiceNo' AS column_name,
       ROUND(100 * COUNTIF(InvoiceNo IS NULL) / COUNT(*), 2) AS missing_percentage
FROM `peppy-web-470203-s5.modulabs_project.project`

UNION ALL
SELECT 'StockCode' AS column_name,
       ROUND(100 * COUNTIF(StockCode IS NULL) / COUNT(*), 2) AS missing_percentage
FROM `peppy-web-470203-s5.modulabs_project.project`

UNION ALL
SELECT 'Description' AS column_name,
       ROUND(100 * COUNTIF(Description IS NULL) / COUNT(*), 2) AS missing_percentage
FROM `peppy-web-470203-s5.modulabs_project.project`

UNION ALL
SELECT 'Quantity' AS column_name,
       ROUND(100 * COUNTIF(Quantity IS NULL) / COUNT(*), 2) AS missing_percentage
FROM `peppy-web-470203-s5.modulabs_project.project`

UNION ALL
SELECT 'InvoiceDate' AS column_name,
       ROUND(100 * COUNTIF(InvoiceDate IS NULL) / COUNT(*), 2) AS missing_percentage
FROM `peppy-web-470203-s5.modulabs_project.project`

UNION ALL
SELECT 'UnitPrice' AS column_name,
       ROUND(100 * COUNTIF(UnitPrice IS NULL) / COUNT(*), 2) AS missing_percentage
FROM `peppy-web-470203-s5.modulabs_project.project`

UNION ALL
SELECT 'CustomerID' AS column_name,
       ROUND(100 * COUNTIF(CustomerID IS NULL) / COUNT(*), 2) AS missing_percentage
FROM `peppy-web-470203-s5.modulabs_project.project`

UNION ALL
SELECT 'Country' AS column_name,
       ROUND(100 * COUNTIF(Country IS NULL) / COUNT(*), 2) AS missing_percentage
FROM `peppy-web-470203-s5.modulabs_project.project`

ORDER BY column_name;

```

[결과 이미지를 넣어주세요]

행	column_name	missing_percenta...
1	Country	0.0
2	CustomerID	24.93
3	Description	0.27
4	InvoiceDate	0.0
5	InvoiceNo	0.0
6	Quantity	0.0
7	StockCode	0.0
8	UnitPrice	0.0

결측치 처리 전략

- **StockCode = '85123A'** 의 **Description** 을 추출하는 쿼리문을 작성하기

```

SELECT DISTINCT Description
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE StockCode = '85123A';

```

[결과 이미지를 넣어주세요]

행	Description ▾
1	WHITE HANGING HEART T-LIG...
2	?
3	wrongly marked carton 22804
4	CREAM HANGING HEART T-LIG...

결측치 처리

- DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시

```
DELETE FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE Description = '?'
OR LOWER(Description) LIKE 'wrongly%';
```

[결과 이미지를 넣어주세요]

i 이 문으로 project의 행 59개가 삭제되었습니다.

11-5. 데이터 전처리(2): 중복값 처리

중복값 확인

- 중복된 행의 수를 세어보기
 - 8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기

```
SELECT
  InvoiceNo,
  StockCode,
  Description,
  Quantity,
  InvoiceDate,
  UnitPrice,
  CustomerID,
  Country,
  COUNT(*) AS dup_count
FROM `peppy-web-470203-s5.modulabs_project.project`
GROUP BY InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country
HAVING COUNT(*) > 1
ORDER BY dup_count DESC;
```

[결과 이미지를 넣어주세요]

UnitPrice ▾	CustomerID ▾	Country ▾	dup_count ▾
2.95	16923	United Kingdom	20
2.95	16923	United Kingdom	12
1.25	14102	United Kingdom	8
1.5	14607	United Kingdom	6
5.95	15044	United Kingdom	6
5.95	15673	United Kingdom	6
5.95	15673	United Kingdom	6
5.95	16735	United Kingdom	6
3.75	17841	United Kingdom	6
1.65	15174	United Kingdom	5

중복값 처리

- 중복값을 제거하는 쿼리문 작성하기
 - CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트

```
CREATE OR REPLACE TABLE `peppy-web-470203-s5.modulabs_project.project_dedup` AS
SELECT DISTINCT
```

```
InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country
FROM `peppy-web-470203-s5.modulabs_project.project`;
```

[결과 이미지를 넣어주세요]

before_rows	after_rows	removed_duplicat...
406829	401604	5225

11-6. 데이터 전처리(3): 오류값 처리

InvoiceNo 살펴보기

- 고유(unique)한 InvoiceNo 의 개수를 출력하기

```
SELECT COUNT(DISTINCT InvoiceNo) AS n_unique_invoices
FROM `peppy-web-470203-s5.modulabs_project.project`;
```

[결과 이미지를 넣어주세요]

행	n_unique_invoices
1	22190

- 고유한 InvoiceNo 를 앞에서부터 100개를 출력하기

```
SELECT *
FROM `peppy-web-470203-s5.modulabs_project.project`
LIMIT 100;
```

[결과 이미지를 넣어주세요]

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate
1	581451	23166	MEDIUM CERAMIC TOP STORA...	-74215	2011-01
2	C541433	23166	MEDIUM CERAMIC TOP STORA...	-74215	2011-01
3	537626	20700	BLACK CAR HUFFY HEADPHONES	12	2010-12
4	537626	20710	PURPLE CHANDERMAH ACETYL...	12	2010-12
5	537626	21195	LARGE HEART MEASURING SP...	12	2010-12
6	537626	22730	ALARM CLOCK BASELINE GREEN	4	2010-12
7	537626	22740	RED SHAWER HEAD ADAPTOR E...	12	2010-12
8	537626	23664	BROWN BOWL SPREADER BOWL...	6	2010-12
9	537626	849199	RED 1 PIECE RETROSPOT OUTL...	4	2010-12
10	537626	851070	BLACK GRAND BAROQUE PRIST...	30	2010-12

- InvoiceNo 가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)

```
SELECT *
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE STARTS_WITH(InvoiceNo, 'C')
LIMIT 100;
```

[결과 이미지를 넣어주세요]

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate
1	C541433	23166	MEDIUM CERAMIC TOP STORA...	-74215	2011-01
2	C545329	M	Manual	-1	2011-03
3	C545329	M	Manual	-1	2011-03
4	C545330	M	Manual	-1	2011-03
5	C547388	37448	CERAMIC CAKE DESIGN SPOTT...	-12	2011-03
6	C547388	84050	PINK HEART SHAPE EGG FRYIN...	-12	2011-03
7	C547388	21914	BLUE HARMONICA IN BOX	-12	2011-03
8	C547388	22784	LANTERN CREAM GAZEBO	-3	2011-03
9	C547388	22645	CERAMIC HEART FAIRY CAKE ...	-12	2011-03
10	C547388	22701	PINK DOG BOWL	-6	2011-03
11	C547388	22419	METAL SIGN TAKE IT OR LEAVE	4	2011-03

- 구매 건 상태가 Canceled 인 데이터의 비율(%) - 소수점 첫번째 자리까지

```
SELECT
  ROUND(100 * COUNTIF(STARTS_WITH(InvoiceNo, 'C')) / COUNT(*), 1) AS canceled_pct
FROM `peppy-web-470203-s5.modulabs_project.project`;
```

[결과 이미지를 넣어주세요]

행	canceled_pct
1	2.2

StockCode 살펴보기

- 고유한 StockCode 의 개수를 출력하기

```
SELECT COUNT(DISTINCT StockCode) AS n_unique_stockcode
FROM `peppy-web-470203-s5.modulabs_project.project`;
```

[결과 이미지를 넣어주세요]

행	n_unique_stockc...
1	3684

- 어떤 제품이 가장 많이 판매되었는지 보기 위하여 StockCode 별 등장 빈도를 출력하기

- 상위 10개의 제품들을 출력하기

```
SELECT StockCode, COUNT(*) AS sell_cnt
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE NOT STARTS_WITH(InvoiceNo, 'C')
  AND Quantity > 0
  AND UnitPrice > 0
GROUP BY StockCode
ORDER BY sell_cnt DESC
LIMIT 10;
```

[결과 이미지를 넣어주세요]

행	StockCode	sell_cnt
1	85123A	2065
2	22423	1894
3	85099B	1659
4	47566	1409
5	84879	1405
6	20725	1346
7	22720	1224
8	POST	1196
9	22197	1110
10	23203	1108

- StockCode 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고

- 숫자가 0~1개인 값들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT DISTINCT StockCode, number_count
FROM (
  SELECT
    StockCode,
    -- 숫자 개수 = 전체 길이 - (숫자 제거 후 길이)
    LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
  FROM `peppy-web-470203-s5.modulabs_project.project`
)
WHERE number_count BETWEEN 0 AND 1
ORDER BY number_count, StockCode
LIMIT 100;
```

[결과 이미지를 넣어주세요]

행	StockCode	number_count
1	BANK CHARGES	0
2	CRUK	0
3	D	0
4	DOT	0
5	M	0
6	PADS	0
7	POST	0
8	C2	1

- **StockCode**의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고
 - 숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트인지 구하기 (소수점 두 번째 자리까지)

```
SELECT ROUND(
  100 * COUNTIF(
    (LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', ''))) BETWEEN 0 AND 1
  ) / COUNT(*), 2) AS pct_rows_0_1_digits
FROM peppy-web-470203-s5.modulabs_project.project;
```

[결과 이미지를 넣어주세요]

행	pct_rows_0_1_dig...
1	0.47

- 제품과 관련되지 않은 거래 기록을 제거하기

```
DELETE FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE StockCode IN (
  SELECT DISTINCT StockCode
  FROM (
    SELECT
      StockCode,
      -- 코드 내 숫자 개수
      LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS n_digits
    FROM `peppy-web-470203-s5.modulabs_project.project`
  )
  WHERE n_digits BETWEEN 0 AND 1 -- 숫자 0~1개(비제품 코드)
);
```

[결과 이미지를 넣어주세요]

이 문으로 project의 행 1,920개가 삭제되었습니다.

Description 살펴보기

- 고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기

```
SELECT
  Description,
  COUNT(*) AS description_cnt
FROM `peppy-web-470203-s5.modulabs_project.project`
GROUP BY Description
ORDER BY description_cnt DESC
LIMIT 30;
```

[결과 이미지를 넣어주세요]

행	Description	description_cnt
1	WHITE HANGING HEART T-LIG...	2070
2	REGENCY CAKESTAND 3 TIER	1905
3	JUMBO BAG RED RETROSPOT	1662
4	ASSORTED COLOUR BIRD ORN...	1418
5	PARTY BUNTING	1416
6	LUNCH BAG RED RETROSPOT	1358
7	SET OF 3 CAKE TINS PANTRY D...	1232
8	LUNCH BAG BLACK SKULL	1126
9	PACK OF 72 RETROSPOT CAKE ...	1080
10	SPOTTY BUNTING	1029
11	PAPER CHAIN KIT 50'S CHRIST...	1029

페이지당 결과 수: 50 ▼ 1 - 30 (전체 30행)

- 서비스 관련 정보를 포함하는 행들을 제거하기

```
DELETE
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE UPPER(Description) LIKE '%POST%'
OR UPPER(Description) LIKE '%CARRIAGE%'
OR UPPER(Description) LIKE '%BANK CHARGES%'
OR UPPER(Description) LIKE '%MANUAL%';
```

[결과 이미지를 넣어주세요]

이 문으로 project의 행 718개가 삭제되었습니다.

- 대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기

```
-- 원본을 덮어씁니다(주의!)
CREATE OR REPLACE TABLE `peppy-web-470203-s5.modulabs_project.project` AS
SELECT
* EXCEPT(Description),
UPPER(TRIM(Description)) AS Description
FROM `peppy-web-470203-s5.modulabs_project.project`;
```

[결과 이미지를 넣어주세요]

이 문으로 이름이 project인 테이블이 교체되었습니다.

UnitPrice 살펴보기

- UnitPrice의 최솟값, 최댓값, 평균을 구하기

```
SELECT
MIN(UnitPrice) AS min_price,
MAX(UnitPrice) AS max_price,
ROUND(AVG(UnitPrice), 2) AS avg_price
FROM `peppy-web-470203-s5.modulabs_project.project`;
```

[결과 이미지를 넣어주세요]

행	min_price	max_price	avg_price
1	0.0	649.5	2.9

- 단가가 0원인 거래의 개수, 구매 수량(Quantity)의 최솟값, 최댓값, 평균 구하기

```

SELECT
  COUNT(*)          AS cnt_zero_price, -- 단가 0원 거래 건수
  MIN(Quantity)     AS min_qty,        -- 수량 최소값
  MAX(Quantity)     AS max_qty,        -- 수량 최대값
  ROUND(AVG(Quantity), 2) AS avg_qty    -- 수량 평균(소수점 2자리)
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE UnitPrice = 0;

```

[결과 이미지를 넣어주세요]

행	cnt_zero_price	min_qty	max_qty	avg_qty
1	33	1	12540	429.52

- **UnitPrice = 0** 를 제거하고 일관된 데이터셋을 유지하기

```

CREATE OR REPLACE TABLE `peppy-web-470203-s5.modulabs_project.project` AS
SELECT *
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE UnitPrice <> 0; -- 0원만 제거

```

[결과 이미지를 넣어주세요]

이 문으로 이름이 project인 테이블이 교체되었습니다.

11-7. RFM 스코어

Recency

- **InvoiceDate** 컬럼을 연월일 자료형으로 변경하기

```

SELECT
  DATE(InvoiceDate) AS InvoiceDay,
  *
FROM `peppy-web-470203-s5.modulabs_project.project`;

```

[결과 이미지를 넣어주세요]

행	InvoiceDay	InvoiceNo	StockCode	Quantity	InvoiceDate
1	2011-01-18	541431	23166	74215	2011-01-18 10:01:00 U
2	2011-01-18	C541433	23166	-74215	2011-01-18 10:17:00 U
3	2010-12-07	537626	84969	6	2010-12-07 14:57:00 U
4	2010-12-07	537626	22212	6	2010-12-07 14:57:00 U
5	2010-12-07	537626	22772	12	2010-12-07 14:57:00 U
6	2010-12-07	537626	22728	4	2010-12-07 14:57:00 U
7	2010-12-07	537626	22375	4	2010-12-07 14:57:00 U
8	2010-12-07	537626	22725	4	2010-12-07 14:57:00 U
9	2010-12-07	537626	22729	4	2010-12-07 14:57:00 U
10	2010-12-07	537626	85232D	3	2010-12-07 14:57:00 U
11	2010-12-07	537626	21171	12	2010-12-07 14:57:00 U

페이지당 결과 수: 50 1 - 50 (전체 404158행)

- 가장 최근 구매 일자를 **MAX()** 함수로 찾아보기


```

SELECT
  MAX(Date(InvoiceDate)) OVER () AS most_recent_date, -- 테이블 전체의 최근 구매일
  Date(InvoiceDate) AS InvoiceDay, -- 각 행의 일자(YYYY-MM-DD)
  *
FROM `peppy-web-470203-s5.modulabs_project.project`;

```

[결과 이미지를 넣어주세요]

행	most_recent_date	InvoiceDay	InvoiceNo	StockCode	Quantity
1	2011-12-09	2011-10-31	573511	23084	48
2	2011-12-09	2011-11-24	578459	22338	96
3	2011-12-09	2011-09-21	567530	23007	1
4	2011-12-09	2011-08-09	C562728	22848	-4
5	2011-12-09	2011-06-10	556415	20717	100
6	2011-12-09	2011-06-15	556917	23235	96
7	2011-12-09	2011-08-18	563614	22734	72
8	2011-12-09	2011-10-05	569650	22546	240
9	2011-12-09	2011-03-03	545536	22504	1
10	2011-12-09	2011-07-19	560473	22835	4
11	2011-12-09	2011-02-01	567576	22901	100

페이지당 결과 수: 50 1 - 50 (전체 404158행) |< > |

- 유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기

```

SELECT
  CustomerID,
  MAX(Date(InvoiceDate)) AS InvoiceDay
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE CustomerID IS NOT NULL
GROUP BY CustomerID;

```

[결과 이미지를 넣어주세요]

행	CustomerID	InvoiceDay
1	12345	2011-10-18
2	12347	2011-12-07
3	12348	2011-09-25
4	12349	2011-11-12
5	12350	2011-05-02
6	12352	2011-11-05
7	12353	2011-09-19
8	12354	2011-04-21
9	12355	2011-05-09
10	12356	2011-11-17
11	12357	2011-11-06

페이지당 결과 수: 50 1 - 50 (전체 404158행) |< > |

- 가장 최근 일자(most_recent_date)와 유저별 마지막 구매일(InvoiceDay)간의 차이를 계산하기

```

WITH last_purchase AS (
  SELECT CustomerID, MAX(Date(InvoiceDate)) AS InvoiceDay
  FROM `peppy-web-470203-s5.modulabs_project.project`
  WHERE CustomerID IS NOT NULL AND NOT STARTS_WITH(InvoiceNo,'C')
  GROUP BY CustomerID
)
SELECT
  CustomerID,
  InvoiceDay,
  MAX(InvoiceDay) OVER () AS most_recent_date,
  DATE_DIFF(MAX(InvoiceDay) OVER (), InvoiceDay, DAY) AS recency_days
FROM last_purchase;

```

[결과 이미지를 넣어주세요]

행	CustomerID	InvoiceDay	most_recent_date	recency_days
1	12381	2011-12-05	2011-12-09	4
2	12401	2011-02-09	2011-12-09	303
3	12678	2011-10-28	2011-12-09	42
4	12770	2011-05-13	2011-12-09	210
5	12949	2011-11-09	2011-12-09	30
6	13127	2011-09-23	2011-12-09	77
7	13299	2011-03-16	2011-12-09	268
8	13379	2011-11-13	2011-12-09	26
9	13524	2011-10-30	2011-12-09	40
10	13689	2011-10-07	2011-12-09	63
11	13687	2011-11-17	2011-12-09	14

페이지당 결과 수: 50 1 - 50 (전체 4334행) < > >>

- 최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 **user_r** 이라는 이름의 테이블로 저장하기

```
CREATE OR REPLACE TABLE `peppy-web-470203-s5.modulabs_project.user_r` AS
WITH sales AS ( -- 취소 제외, 날짜만 추출
SELECT
  CustomerID,
  DATE(InvoiceDate) AS InvoiceDay
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE CustomerID IS NOT NULL
  AND NOT STARTS_WITH(InvoiceNo, 'C')
),
last_purchase AS ( -- 고객별 마지막 구매일
SELECT
  CustomerID,
  MAX(InvoiceDay) AS InvoiceDay
FROM sales
GROUP BY CustomerID
),
most_recent AS ( -- 전체에서 가장 최근 일자
SELECT MAX(InvoiceDay) AS most_recent_date
FROM sales
)
SELECT
  lp.CustomerID,
  lp.InvoiceDay,          -- 고객별 마지막 구매일
  mr.most_recent_date,    -- 데이터 전체의 가장 최근 일자
  DATE_DIFF(mr.most_recent_date, lp.InvoiceDay, DAY) AS recency_days
FROM last_purchase lp
CROSS JOIN most_recent mr;
```

[결과 이미지를 넣어주세요]

행	CustomerID	InvoiceDay	most_recent_date	recency_days
1	15564	2011-12-09	2011-12-09	0
2	16654	2011-12-09	2011-12-09	0
3	13626	2011-12-09	2011-12-09	0
4	14651	2011-12-09	2011-12-09	0
5	17501	2011-12-09	2011-12-09	0
6	13526	2011-12-09	2011-12-09	0
7	17428	2011-12-09	2011-12-09	0
8	16182	2011-12-09	2011-12-09	0
9	17490	2011-12-09	2011-12-09	0
10	13518	2011-12-09	2011-12-09	0
11	14446	2011-12-09	2011-12-09	0
12	13484	2011-12-09	2011-12-09	0
13	17581	2011-12-09	2011-12-09	0
14	17389	2011-12-09	2011-12-09	0
15	13462	2011-12-09	2011-12-09	0
16	14441	2011-12-09	2011-12-09	0
17	15344	2011-12-09	2011-12-09	0
18	13433	2011-12-09	2011-12-09	0
19	13211	2011-12-09	2011-12-09	0
20	13919	2011-12-09	2011-12-09	0
21	16058	2011-12-09	2011-12-09	0
22	13433	2011-12-09	2011-12-09	0
23	13113	2011-12-09	2011-12-09	0

페이지당 결과 수: 50 1 - 50 (전체 4334행) < > >>

Frequency

- 고객마다 고유한 InvoiceNo의 수를 세어보기

```
SELECT
  CustomerID,
  COUNT(DISTINCT InvoiceNo) AS purchase_cnt
```

```
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE CustomerID IS NOT NULL
  AND NOT STARTS_WITH(InvoiceNo, 'C') -- 취소건 제외(권장)
GROUP BY CustomerID
ORDER BY purchase_cnt DESC;
```

[결과 이미지를 넣어주세요]

항목	CustomerID	purchase_cnt
1	12748	204
2	14911	194
3	17841	124
4	15889	97
5	13271	97
6	14445	95
7	13271	84
8	14445	75
9	15889	62
10	14298	62
11	14156	48

• 각 고객 별로 구매한 아이템의 총 수량 더하기

```
SELECT
  CustomerID,
  SUM(Quantity) AS item_cnt
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE CustomerID IS NOT NULL
  AND NOT STARTS_WITH(InvoiceNo, 'C') -- 취소건 제외
  AND Quantity > 0 -- 유효 수량만
GROUP BY CustomerID
ORDER BY item_cnt DESC;
```

[결과 이미지를 넣어주세요]

항목	CustomerID	item_cnt
1	14646	196556
2	16446	80997
3	14911	79728
4	12415	77173
5	12346	74215
6	17450	69993
7	17511	64524
8	18102	64114
9	13694	63312
10	14298	58187
11	14156	57872

• 전체 거래 건수 계산과 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기

```
CREATE OR REPLACE TABLE `peppy-web-470203-s5.modulabs_project.user_rf` AS

-- (1) 전체 거래 건수(고유 InvoiceNo 수)
WITH purchase_cnt AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT InvoiceNo) AS purchase_cnt
  FROM `peppy-web-470203-s5.modulabs_project.project`
  WHERE CustomerID IS NOT NULL
    AND NOT STARTS_WITH(InvoiceNo, 'C') -- 취소 제외
  GROUP BY CustomerID
),

-- (2) 구매한 아이템 총 수량(Quantity 합)
item_cnt AS (
  SELECT
    CustomerID,
    SUM(Quantity) AS item_cnt
```

```

FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE CustomerID IS NOT NULL
  AND NOT STARTS_WITH(InvoiceNo, 'C')    -- 취소 제외
  AND Quantity > 0                      -- 유효 수량만
GROUP BY CustomerID
)

-- 기존 user_r(Recency)와 결합
SELECT
  pc.CustomerID,
  pc.purchase_cnt,
  ic.item_cnt,
  ur.recency_days
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
  ON pc.CustomerID = ic.CustomerID
JOIN `peppy-web-470203-s5.modulabs_project.user_r` AS ur
  ON pc.CustomerID = ur.CustomerID;

```

[결과 이미지를 넣어주세요]

스키마	세부정보	미리보기	데이터 탐색기	프리뷰
행	CustomerID	purchase_cnt	item_cnt	recency_days
1	12713	1	480	0
2	14569	1	79	1
3	13298	1	96	1
4	15520	1	314	1
5	13436	1	72	1
6	14204	1	82	2
7	15195	1	1404	2
8	15471	1	265	2
	14087	1	250	2
10	16528	1	171	3
11	12478	1	233	3
12	14578	1	240	3
13	16569	1	93	3
14	15992	1	17	3
15	15318	1	642	3
16	12442	1	181	3
17	12650	1	250	3
18	17914	1	473	3
19	13790	1	748	4
20	17383	1	150	4
21	15097	1	164	4
22	14219	1	78	4
23	12367	1	172	4

Monetary

- 고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)

```

SELECT
  CustomerID,
  ROUND(SUM(Quantity * UnitPrice), 1) AS user_total
FROM `peppy-web-470203-s5.modulabs_project.project`
WHERE CustomerID IS NOT NULL
  AND NOT STARTS_WITH(InvoiceNo, 'C') -- 취소건 제외
  AND Quantity > 0                    -- 유효 수량
  AND UnitPrice > 0                  -- 유효 단가
GROUP BY CustomerID
ORDER BY user_total DESC;

```

[결과 이미지를 넣어주세요]

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	480	0	784.1	784.1
2	13298	1	96	1	360.0	360.0
3	14569	1	79	1	227.4	227.4
4	13436	1	72	1	181.9	181.9
5	15520	1	314	1	343.5	343.5
6	15195	1	1404	2	3861.0	3861.0
7	14087	1	250	2	193.8	193.8
8	14204	1	82	2	161.0	161.0
9	15471	1	265	2	462.8	462.8
10	14578	1	240	3	168.6	168.6
11	15992	1	17	3	42.0	42.0
12	15318	1	642	3	312.6	312.6
13	12478	1	233	3	546.0	546.0
14	16528	1	171	3	244.4	244.4
15	16569	1	93	3	124.2	124.2
16	17914	1	473	3	336.4	336.4
17	12650	1	250	3	242.4	242.4
18	12442	1	181	3	144.1	144.1
19	14219	1	78	4	89.9	89.9
20	18015	1	157	4	120.0	120.0
21	17383	1	150	4	199.3	199.3
22	16597	1	184	4	90.0	90.0
23	13790	1	748	4	348.8	348.8

고객별 평균 거래 금액 계산

- 고객별 평균 거래 금액을 구하기 위해 1) **data** 테이블을 **user_rf** 테이블과 조인(LEFT JOIN) 한 후, 2) **purchase_cnt** 로 나누어서 3) **user_rfm** 테이블로 저장하기

```
CREATE OR REPLACE TABLE `peppy-web-470203-s5.modulabs_project.user_rfm` AS
SELECT
  rf.CustomerID AS CustomerID,
  rf.purchase_cnt,
  rf.item_cnt,
  rf.recency_days AS recency,
  ut.user_total,
  ROUND(ut.user_total / NULLIF(rf.purchase_cnt, 0), 2) AS user_average
FROM `peppy-web-470203-s5.modulabs_project.user_rf` AS rf
LEFT JOIN (
  -- 고객별 총 지출액 (취소 제외 + 유효 수량/단가)
  SELECT
    CustomerID,
    ROUND(SUM(Quantity * UnitPrice), 1) AS user_total
  FROM `peppy-web-470203-s5.modulabs_project.project`
  WHERE CustomerID IS NOT NULL
  AND NOT STARTS_WITH(InvoiceNo, 'C')
  AND Quantity > 0
  AND UnitPrice > 0
  GROUP BY CustomerID
) AS ut
ON rf.CustomerID = ut.CustomerID;
```

[결과 이미지를 넣어주세요]

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	480	0	784.1	784.1
2	13298	1	96	1	360.0	360.0
3	14569	1	79	1	227.4	227.4
4	13436	1	72	1	181.9	181.9
5	15520	1	314	1	343.5	343.5
6	15195	1	1404	2	3861.0	3861.0
7	14087	1	250	2	193.8	193.8
8	14204	1	82	2	161.0	161.0
9	15471	1	265	2	462.8	462.8
10	14578	1	240	3	168.6	168.6
11	15992	1	17	3	42.0	42.0
12	15318	1	642	3	312.6	312.6
13	12478	1	233	3	546.0	546.0
14	16528	1	171	3	244.4	244.4
15	16569	1	93	3	124.2	124.2
16	17914	1	473	3	336.4	336.4
17	12650	1	250	3	242.4	242.4
18	12442	1	181	3	144.1	144.1
19	14219	1	78	4	89.9	89.9
20	18015	1	157	4	120.0	120.0
21	17383	1	150	4	199.3	199.3
22	16597	1	184	4	90.0	90.0
23	13790	1	748	4	348.8	348.8

RFM 통합 테이블 출력하기

- 최종 user_rfm 테이블을 출력하기

```
SELECT *  
FROM `peppy-web-470203-s5.modulabs_project.user_rfm`;
```

[결과 이미지를 넣어주세요]

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	480	0	784.1	784.1
2	13298	1	96	1	360.0	360.0
3	14569	1	79	1	227.4	227.4
4	13436	1	72	1	181.9	181.9
5	15520	1	314	1	343.5	343.5
6	15195	1	1404	2	3861.0	3861.0
7	14087	1	250	2	193.8	193.8
8	14204	1	82	2	161.0	161.0
9	15471	1	265	2	462.8	462.8
10	14578	1	240	3	168.6	168.6
11	15609	1	17	3	49.0	49.0

페이지당 결과 수: 50 1 - 50 (전체 4334행) |< < > >|

11-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

- 1) 고객 별로 구매한 상품들의 고유한 수를 계산하기
- 2) user_rfm 테이블과 결과를 합치기
- 3) user_data 라는 이름의 테이블에 저장하기

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_data AS  
WITH unique_products AS (  
  SELECT  
    CustomerID,  
    COUNT(DISTINCT StockCode) AS unique_products  
  FROM project_name.modulabs_project.data  
  GROUP BY CustomerID  
)  
SELECT ur.*, up.* EXCEPT (CustomerID)  
FROM project_name.modulabs_project.user_rfm AS ur  
JOIN unique_products AS up  
ON ur.CustomerID = up.CustomerID;
```

[결과 이미지를 넣어주세요]

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_prod...
1	12713	1	480	0	784.1	784.1	36
2	13298	1	96	1	360.0	360.0	2
3	13436	1	72	1	181.9	181.9	11
4	15520	1	314	1	343.5	343.5	18
5	14569	1	79	1	227.4	227.4	10
6	15195	1	1404	2	3861.0	3861.0	1
7	14204	1	82	2	161.0	161.0	36
8	15471	1	265	2	462.8	462.8	66
9	14087	1	250	2	193.8	193.8	60
10	15318	1	642	3	312.6	312.6	33
11	12650	1	250	3	242.4	242.4	19
12	16528	1	171	3	244.4	244.4	17
13	15992	1	17	3	42.0	42.0	3
14	16569	1	93	3	124.2	124.2	5
15	12442	1	181	3	144.1	144.1	11
16	14578	1	240	3	168.6	168.6	24
17	17914	1	473	3	336.4	336.4	72
18	12478	1	233	3	546.0	546.0	35
19	12367	1	172	4	150.9	150.9	10
20	18015	1	157	4	120.0	120.0	46
21	17383	1	150	4	199.3	199.3	49
22	16597	1	184	4	90.0	90.0	7
23	14219	1	78	4	89.9	89.9	7

페이지당 결과 수: 50 ▼ 1 - 50 (전체 4334행) |< < > >

2. 평균 구매 주기

- 고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)
 - 균 구매 소요 일수를 계산하고, 그 결과를 `user_data` 에 통합

```

CREATE OR REPLACE TABLE project_name.modulabs_project.user_data AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
  SELECT
    CustomerID,
    CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_interval
  FROM (
    -- (1) 구매와 구매 사이에 소요된 일수
    SELECT
      CustomerID,
      DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY) AS interval_
    FROM
      project_name.modulabs_project.data
    WHERE CustomerID IS NOT NULL
  )
  GROUP BY CustomerID
)

SELECT u.*, pi.* EXCEPT (CustomerID)
FROM project_name.modulabs_project.user_data AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;

```

[결과 이미지를 넣어주세요]

스키마	세부 정보	데이터보기	데이터를 탐색하기	필터	종류	계보	데이터의 구조를	데이터를 활용
명	CustomerID	purchase_date	total_price	cancel_rate	user_detail	user_age	user_gender	user_name
1	12713	1	480	0	784.1	784.1	36	
2	13296	1	96	1	360.0	360.0	2	
3	14689	1	72	1	181.9	181.9	11	
4	15520	1	214	1	343.5	343.5	18	
5	14689	1	79	1	227.4	227.4	10	
6	15195	1	1404	2	3861.0	3861.0	1	
7	14204	1	82	2	161.0	161.0	36	
8	15471	1	265	2	462.8	462.8	66	
9	14087	1	250	2	193.8	193.8	60	
10	15116	1	642	3	312.6	312.6	39	
11	12680	1	250	3	242.4	242.4	19	
12	16528	1	171	3	244.4	244.4	17	
13	15982	1	17	3	42.0	42.0	9	
14	16569	1	93	3	124.2	124.2	9	
15	12442	1	181	3	144.1	144.1	11	
16	14278	1	240	3	168.6	168.6	24	
17	17914	1	473	3	336.4	336.4	72	
18	12478	1	235	3	346.0	346.0	38	
19	12867	1	172	4	150.9	150.9	10	
20	18015	1	127	4	120.0	120.0	46	
21	17383	1	150	4	199.3	199.3	49	
22	16897	1	184	4	90.0	90.0	7	
23	14714	1	78	4	89.9	89.9	7	

3. 구매 취소 경향성

- 고객의 취소 패턴 파악하기
 - 1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
 - 2) 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
 - 취소 빈도와 취소 비율을 계산하고 그 결과를 **user_data** 에 통합하기
(취소 비율은 소수점 두번째 자리)

CREATE OR REPLACE TABLE project_name.modulabs_project.user_data AS

```
WITH TransactionInfo AS (
  SELECT
    CustomerID,
    # [[YOUR QUERY]] AS total_transactions,
    # [[YOUR QUERY]] AS cancel_frequency
  FROM project_name.modulabs_project.data
  # [[YOUR QUERY]]
)
```

```
SELECT u.*, t.* EXCEPT(CustomerID), # [[YOUR QUERY]] AS cancel_rate
FROM `project_name.modulabs_project.user_data` AS u
LEFT JOIN TransactionInfo AS t
ON # [[YOUR QUERY]];
```

[결과 이미지를 넣어주세요]

스키마	세부 정보	데이터보기	데이터를 탐색하기	필터	종류	계보	데이터의 구조를	데이터를 활용
명	CustomerID	purchase_date	total_price	cancel_rate	user_detail	user_age	user_gender	user_name
1	12713	1	480	0	784.1	784.1	36	
2	13296	1	96	1	360.0	360.0	2	
3	14689	1	72	1	181.9	181.9	11	
4	15520	1	214	1	343.5	343.5	18	
5	14689	1	79	1	227.4	227.4	10	
6	15195	1	1404	2	3861.0	3861.0	1	
7	14204	1	82	2	161.0	161.0	36	
8	15471	1	265	2	462.8	462.8	66	
9	14087	1	250	2	193.8	193.8	60	
10	15116	1	642	3	312.6	312.6	39	
11	12680	1	250	3	242.4	242.4	19	
12	16528	1	171	3	244.4	244.4	17	
13	15982	1	17	3	42.0	42.0	9	
14	16569	1	93	3	124.2	124.2	9	
15	12442	1	181	3	144.1	144.1	11	
16	14278	1	240	3	168.6	168.6	24	
17	17914	1	473	3	336.4	336.4	72	
18	12478	1	235	3	346.0	346.0	38	
19	12867	1	172	4	150.9	150.9	10	
20	18015	1	127	4	120.0	120.0	46	
21	17383	1	150	4	199.3	199.3	49	
22	16897	1	184	4	90.0	90.0	7	
23	14714	1	78	4	89.9	89.9	7	

- 다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 **user_data** 를 출력하기

```
SELECT *
FROM `peppy-web-470203-s5.modulabs_project.user_data`;
```

[결과 이미지를 넣어주세요]

쿼리 결과								
결과 저장 다음에서 열기								
작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프								
행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	uniqu	
1	17942	1	38	7	77.5	77.5		
2	13877	1	108	86	117.2	117.2		
3	16789	1	32	8	80.8	80.8		
4	13786	1	136	367	230.4	230.4		
5	14908	1	132	74	277.8	277.8		
6	14348	1	183	260	409.6	409.6		
7	17901	1	24	29	110.4	110.4		
8	16236	1	184	78	432.2	432.2		
9	17985	1	183	22	635.0	635.0		
10	18192	1	339	71	958.0	958.0		
11	16076	1	088	77	1068.8	1068.8		
페이지당 결과 수: 50 1 - 50 (전체 4334행) < < > >								

회고

[회고 내용을 작성해주세요]

Keep :

Problem :

Try :